

Hackathon 2 — ¿La escala cambia la historia?

PCA con Palmer Penguins | Trabajo en parejas | 90 minutos

Escenario. Un equipo debe resumir cuatro mediciones físicas de pingüinos en una representación de menor dimensión. Una persona propone aplicar PCA después de centrar los datos; otra advierte que la masa está en gramos y las demás variables en milímetros. Su equipo debe decidir, con evidencia reproducible, si la escala cambia la historia que cuenta PCA.

Objetivo y pregunta central

El objetivo es usar SVD para construir PCA, comparar dos preprocesamientos y evaluar qué información se conserva al reducir la dimensión. La pregunta central es: ¿cómo cambian las componentes principales y las conclusiones cuando se usan las unidades originales o se estandarizan las variables?

Datos disponibles

El paquete contiene una copia local del conjunto Palmer Penguins. No se requiere conexión a Internet. El archivo original tiene 344 filas; dos carecen de las cuatro mediciones numéricas. La columna species se usa únicamente para colorear e interpretar la proyección, no para calcular PCA.

Campo	Significado y unidad
species	especie: Adelie, Chinstrap o Gentoo
bill_length_mm	longitud del pico, en milímetros
bill_depth_mm	profundidad del pico, en milímetros
flipper_length_mm	longitud de la aleta, en milímetros
body_mass_g	masa corporal, en gramos

Condiciones de trabajo

- Trabajen en parejas. Una persona conduce el código y la otra verifica cálculos e interpretaciones; intercambien roles después de la Tarea 3.
- Usen `numpy.linalg.svd`. No usen `sklearn.decomposition.PCA`: el objetivo es demostrar que comprenden el procedimiento.
- Las respuestas escritas deben citar resultados numéricos o elementos del gráfico. Un gráfico sin interpretación no demuestra comprensión.
- No modifiquen `data/penguins.csv`. Guarden la figura en `output/pca_penguins.png`.

Tareas

Tarea 1. Auditar y limpiar los datos — 10 minutos

- Cargar el CSV, revisar forma, columnas y faltantes de species y las cuatro mediciones.
- Eliminar únicamente las filas incompletas para esas cinco columnas y construir una matriz numérica X de tamaño $n \times 4$.
- **Respuesta 1.** Indicar cuántas filas se eliminan, por qué es razonable aquí y qué limitación tiene eliminar observaciones incompletas.

Tarea 2. Predecir y preparar las matrices — 10 minutos

- Antes de calcular PCA, comparar unidades, rangos y desviaciones estándar. Predecir qué variable dominará PC1 si solo se centra la matriz. Explicar la razón.
- Construir X_{centered} restando la media de cada columna.

- Construir Z con media cero y desviación estándar muestral uno por columna:

$$z_{ij} = \frac{(x_{ij} - \mu_j)}{s_j}$$

- Verificar numéricamente las medias y desviaciones estándar de Z .

Tarea 3. Calcular PCA mediante SVD — 25 minutos

Implementar una función `pca_svd(A)` a partir de la descomposición:

$$A = U\Sigma V^T$$

- Calcular puntuaciones como U multiplicado columna a columna por los valores singulares. Las filas de V^T son las direcciones principales.
- Calcular la proporción de varianza explicada por cada componente:

$$r_i = \frac{\sigma_i^2}{\sum \sigma_j^2}$$

- Aplicar la función a X_{centered} y a Z . No ordenar nuevamente los valores singulares: `numpy.linalg.svd` ya los devuelve de mayor a menor.

Tarea 4. Comparar varianza explicada y cargas — 15 minutos

- Crear una tabla con proporción y proporción acumulada para las cuatro componentes en ambos preprocesamientos.
- Comparar las cargas de PC1. Para identificar la variable dominante, usar magnitudes absolutas; una componente completa puede cambiar de signo sin alterar PCA.
- Calcular el menor número k_{90} de componentes estandarizadas que conserva al menos 90% de la varianza.
- **Respuesta 3.** Confirmar o rechazar la predicción previa usando la proporción de PC1 y su carga dominante en el caso no estandarizado.
- **Respuesta 4.** Interpretar PC1 estandarizada como combinación de rasgos; no limitarse a copiar las cargas.
- **Respuesta 5.** Indicar si dos componentes alcanzan 90%, la proporción acumulada y k_{90} .

Tarea 5. Visualizar las representaciones — 15 minutos

- Crear una figura con dos paneles PC1–PC2: datos solo centrados a la izquierda y estandarizados a la derecha.
- Colorear por especie e incluir título, leyenda, etiquetas y porcentaje de varianza explicado en cada eje.
- Guardar la figura como `output/pca_penguins.png`.
- **Respuesta 6.** Comparar ambos paneles, describir al menos un patrón visible y aclarar si las especies quedan perfectamente separadas. PCA no debe presentarse como clasificador.

Tarea 6. Reconstruir y medir la pérdida — 10 minutos

Reconstruir los datos estandarizados con las dos primeras componentes:

$$\hat{Z}_2 = T_2 V_2^T$$

- Invertir la estandarización para volver a milímetros y gramos.
- Calcular el error relativo de Frobenius en Z y el RMSE de cada variable en unidades originales.
- Verificar la identidad:

$$\frac{\|Z - \hat{Z}_2\|_F}{\|Z\|_F} = \sqrt{1 - (r_1 + r_2)}$$

Tarea 7. Tomar una decisión y verificar — 5 minutos

- **Respuesta 7.** Recomendar preprocesamiento y número de componentes para dos propósitos distintos: comunicar en un gráfico 2D y conservar al menos 90% para análisis interno. Justificar con varianza, cargas, gráfico y reconstrucción.
- Reiniciar el kernel, ejecutar todo y guardar el notebook sin errores.

Verificación final y entrega

Desde la carpeta hackathon2_student, después de guardar el notebook, ejecutar:

```
uv run python verify_notebook.py
```

- El mensaje final debe ser VERIFICACIÓN COMPLETA y la celda de comprobaciones públicas debe terminar sin errores.
- Entregar Hackathon_2_Starter.ipynb ejecutado, output/pca_penguins.png y los nombres de ambos integrantes al inicio del notebook.
- Ambos integrantes deben poder explicar la predicción, el efecto de estandarizar, el criterio de 90% y la decisión final.

Criterios de evaluación

Criterio	Peso
Auditoría, predicción y tratamiento de faltantes	15%
Centrado, estandarización e invariantes	15%
PCA implementado correctamente con SVD	25%
Varianza explicada, cargas y criterio k90	15%
Visualización comparativa e interpretación	10%
Reconstrucción, errores y decisión final	15%
Ejecución reproducible, claridad y explicación en pareja	5%